



논문 설명

2025 빅데분 실무 팀프로젝트 논문설명 페이지

목표

- 온라인 쇼핑몰 구매 데이터를 활용한 추천 시스템 구축

구성

- 추천 시스템 = 협업 기반 필터링 + 콘텐츠 기반 필터링

구매 가능성 향상 모델 개발

협업 기반 필터링
(COLLABORATIVE FILTERING)

나와 비슷한 사용자가 구매한 상품 추천

추천 시스템

+

콘텐츠 기반 필터링
(CONTENT-BASED FILTERING)

내가 구매한 상품과 비슷한 상품 추천

알고리즘 및 논문 설명

▼ 전처리

▼ CF

ALS

협업 필터링이란 나와 비슷한 사용자가 구매한 상품을 추천하는 알고리즘임

이를 가장 쉽게 구현하기 위해서, 추천 시스템을 사용자와 상품의 관계를 나타내는 거대한 표를 만드는 것이라고 생각해보자.

사용자 \ 구매 여부	휴지	가위	연필	
민수	O			
경희				
철우			O	
태범		O		
.....				

위와 같은 식으로 거대한 표를 채우는 거라고 생각하면 된다.

그런데 상품의 종류도 많고, 사용자도 많으니 자연스레 표의 대부분은 비어있지 않을까?

→ 이러한 데이터를 희소행렬, Sparse하다고 표현한다.

CF는 기본적으로 이 비어있는 칸을 예측해서 민수가 연필을 살지 말지, 태범이 휴지를 살지 말지 예측하는 문제를 푸는 알고리즘이다.

(이를 수학적으로 말하면 Low-Rank Matrix Reconstruction이라 하고, 링크된 논문의 제목도 이러하다)

이제 CF가 풀어야 하는 문제를 알았으니, 다음으로 ALS가 뭐하는 알고리즘인지 살펴보자

ALS는 이 문제를 해결하기 위해 우선 위의 큰 데이터를 두 조각으로 나눈다

사용자 요인 행렬(L)과 상품 요인 행렬(R)이렇게 두 가지로 나누는데,

- L: 각 사용자가 어떤 성향을 가지고 있는가?
- R: 각 상품이 어떠한 특징을 가지고 있는가?

를 의미한다.

또한, 전체 평점(또는 구매 여부) 데이터는 $L \times R$ 이라는 행렬곱을 통해 근사할 수 있다 (정답을 구하는 것이 아니라 정답을 근사하는 것이고, 정확한 값은 아닌데 애초에 예측하는 알고리즘이라 그렇다)

그런데 중요한 건 저 L, R 두 행렬 모두 직접 구할 수 없다는 것이다

그래서 ALS가 어떻게 동작하냐면

1. L을 임의로 정함 (= 빈 행렬에 랜덤한 값을 채워넣음)

2. 이 L을 이용해서 R을 최소제곱법으로 계산함
3. 이번에는 계산된 R로 L을 최소제곱법으로 계산함
4. 2번과 3번을 반복하며 loss 최소화하기

이렇게 동작한다.

▼ 최소제곱법이 뭔가요

독립변수 X와 종속변수 Y가 있을 때, 이 둘이 선형관계라고 가정한다면 식은 아래와 같이 세워진다.

$$Y = f(X) = aX + b$$

이때 error(=residual)은 아래와 같다

$$e_i = |Y_i - f(X_i)|$$

데이터의 개수만큼 error가 있을텐데, 이 error들을 제곱해서 모두 더한걸 SSE라 한다

$$SSE = \sum_{i=1}^n (Y_i - aX_i - b)^2$$

이후 이 SSE를 a와 b로 편미분한다

$$\frac{\partial(SSE)}{\partial a} = 0, \frac{\partial(SSE)}{\partial b} = 0$$

Y, A, X를 행렬로 표현하면

$$\mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_3 \end{bmatrix}, \mathbf{A} = \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_3 & 1 \end{bmatrix}, \mathbf{X} = \begin{bmatrix} a \\ b \end{bmatrix}$$

$$\mathbf{A}^T \mathbf{A} \mathbf{X} = \mathbf{A}^T \mathbf{Y}$$

이걸 풀면

$$\mathbf{X} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{Y}$$

따라서, 최소제곱법이란 변수들이 선형관계인 식에서 파라미터를 구하는 통계적 방법이다

OLS라고도 함

ALS 예시

회식 메뉴를 정해야 하는데, 사람 100명에 메뉴는 100개중 하나를 정해야 하고, 어떤 사람이 어떤 메뉴를 좋아하는지는 약 10명정도만 알 수 있다고 하자

ALS의 동작방식은 아래와 같다

1. 사람들의 메뉴 취향 (L 행렬 이라고 할 수 있다)을 임의로 추정
→ 예를 들자면 10명이 동일하게 좋아하는 메뉴가 있다고 해 보자
그 메뉴가 매운 메뉴일 때, 메뉴 취향은 매운맛을 좋아한다고 추정할 수 있다
2. 그걸 바탕으로 메뉴들의 특징 (R 행렬 이라고 할 수 있다)을 계산
→ 사람들이 매운맛을 좋아하므로. 이 메뉴는 맵다라고 추정할 수 있다
3. 그 정보를 이용해서 사람들의 메뉴 취향을 보정
→ 매운걸 좋아하는 사람이라면 이 메뉴에도 높은 점수를 줄 것이다 라고 예측한다
4. 이걸 반복해서 점점 더 정확한 예측을 함

ALS의 장점


- 사용자 하나당 계산하는 과정이 서로 독립적임, 병렬화로 속도개선 용이
- 수학적으로 최적화된 알고리즘이라 딥러닝같이 확률 기반으로 추론하는 부분 없이 바로 바로 진동 없이 일정하게 수렴하는걸 기대할 수 있음
- 논문에 따르면 데이터에 약간의 노이즈가 있어도 수렴이 가능하며, 이론적 상한치에 근접한다고 설명함
- 해석이 쉬운데, 예를 들어 영화를 추천하는 문제에서 이 사람은 액션영화를 좋아하는데, 이 영화는 장면의 격렬함 지수가 높다. 그래서 추천할만 하다 라고 해석할 수 있고, 추천 이유를 설명하기도 쉽다

▼ CB

GNN

GNN은 그래프 형태의 데이터에 인공지능을 적용하는 신경망 구조이다

그래프가 뭔가요



그래프란 노드와 그 노드들을 잇는 엣지로 구성된 데이터를 의미한다

엣지는 방향과 가중치를 가질 수 있다

이거 왜 쓰나요

csv처럼 표로 정리하기 쉬운 데이터만 있으면 참 좋겠지만, 세상에는 그렇지 않은 데이터들도 많다.

SNS의 인간관계, 상품 간의 유사성 데이터 등등은 표로 정리하기 참 힘든 데이터들이다

어떻게 동작하나요

이름에 신경망 (Graph **Neural Network**)가 들어간 만큼 자세하게 설명하려면 신경망부터 먼저 설명해야 하지만, 최대한 쉽게 설명하자면 GNN이란 각 노드가 옆에 있는 노드에게서 정보를 받아서 노드 자기 자신을 업데이트하는 구조이다

이렇게 각 노드가 이웃에게서 정보를 받아 자기 상태를 업데이트하는 구조를 message passing / information aggregation이라고 한다

예를 들어서 영화를 추천하는 시스템이라면 노드로는 사용자나 영화가, 엣지로는 “이 사용자가 영화를 봤다”라는 정보가 될 수 있다.

그리고 GNN은

1. 사용자 노드는 자신이 본 영화들의 정보를 수집한다
2. 영화 노드는 자신을 본 사용자들의 정보를 수집한다
3. 이 정보들을 주고받으며 서로의 표현 (나는 어떤 사람이고, 나는 어떤 영화다 이거)을 점점 더 정밀하고 자세하게, 깔끔하게 만든다

의 과정을 거쳐 동작하게 된다

GNN 설계방법

1. 그래프 구조 찾기
 - a. 데이터가 원래 그래프 형태 → 그대로 사용

- b. 아니라면 그래프 형태로 데이터 수정
- 2. 그래프 유형 정의
 - a. 엣지의 방향이 있는가?
 - b. 노드와 엣지가 여러종류인가?
 - c. 시간에 따라 그래프의 형태가 변하는가?
 - d. 위의 것들을 종합하여 그래프 유형 정의
- 3. 목표 정의
 - a. 노드, 엣지, 그래프 전체 중 뭘 예측할지
 - b. 예를 들어 노드 분류면 사용자 성별 예측, 엣지 예측이면 누가 누구를 팔로우할까? 같은 것
- 4. 모듈 설계 및 조립
 - a. Propagation, Sampling, Pooling 등 모델 설계 및 조립


그래서 이거 CB에 어떻게 씬

전통적인 CB 알고리즘은 각 콘텐츠를 벡터로 표시하고, 코사인 유사도 등의 벡터간의 유사도를 측정하는 기법으로 추천할 데이터를 선정한다


예를 들어 영화 추천이라면 영화의 장르, 배우 및 감독, 영화의 키워드 등이 이 영화의 특징이 되어 벡터로 표현되는 느낌임

근데 이 방식에는 약점이 있다

- 1. 이 배우가 저 영화에도 나왔다같은 연결을 반영하기 어려움
- 2. 감독 + 배우의 조합과 같은 특징 사이의 상호작용이 무시됨
- 3. 이 영화와 비슷한 주제의 웹툰처럼 새로운 특징이 생기고 다층적 관계가 생기면 기존의 방식에 적용하기 어려움



기존의 벡터 방식은 이렇게 영화에 대한 정보를 저장해놓고, 다른 벡터들과의 유사도를 측정하는 방식이다



반면 그래프 방식은 이렇게 영화, 감독, 배우, 장르 등의 특징들을 노드로 해서 각 노드 사이의 연결관계를 표현하는 방식이다

위의 한국영화 그래프에 GNN을 적용하게 되면 각 노드들이 이웃한 노드로부터 정보를 받아 자기 자신을 업데이트한다.

이 때 확률을 기반으로 업데이트되는 신경망의 특성에 따라 같은 작가의 작품이지만 장르가 다르면 관계를 약하게, 같은 장르라도 자주 함께 소비된다면 연결고리를 강하게 하는 식으로 각 노드들 사이의 문맥 또한 학습된다

이렇게 하면 학습이 완료된 그래프에서 사용자에게 어떠한 노드를 추천해줄지를 연결고리의 강도를 보고 쉽게 파악할 수 있다

예를 들어, 위의 그래프에서 사용자가 [괴물]을 보고 좋은 평가를 남겼다면 같은 감독의 작품인 [기생충]이나 [설국열차]를 추천해주는 식이고, [기생충]을 보고 좋은 평가를 남겼다면 같은 장르인 [올드보이]나 [친절한 금자씨]를 추천해주는 식이다

이는 각 사용자마다 독립적으로 반영할 수 있어 사용자에게 비슷한 장르의 영화와 같은 배우가 나오는 영화 이렇게 두 개를 추천해줬는데 그 중 비슷한 장르의 영화를 골랐을 경우, 신경망은 다음부터는 같은 배우보다는 비슷한 장르의 영화를 더 추천하는 방향으로 학습된다