

온라인 쇼핑몰 구매 데이터를 활용한 상품 추천 시스템 구축 (EDA 및 모델 설명)

2020144005 전자공학과 김윤성
2021316016 IT경영학과 박승원
2020314001 IT경영학과 강윤모
2022312042 경영학과 송혜은
2022134047 AI로봇전공 서원

01	PURPOSE OF EDA	EDA 목적
02	DATA-SET EXPLANATION	데이터 세트 설명
03	EDA RESULTS	EDA 결과
04	EDA SUMMARIZATION	EDA 요약
05	PROPOSED MODEL	모델

EDA 목적

- 최적의 상품 추천 모델 개발을 위한 **변수를 선별**
- 불필요한 정보를 제거하여 **데이터 효율성을 증가**
- 각 데이터 세트가 포함하고 있는 **정보의 양과 특성 분포를 파악**
- 분석 및 추천 알고리즘 설계 시 **참고할 기초 자료로 활용**

시스템 구축에 필요한 **주요 변수를 명확히 정의하고,**
향후 모델 학습 방향을 구체화

데이터 구성 소개

사용 데이터셋

Category_tree.csv

(상품 카테고리 구조)

```
--- [category_tree.csv] 결측치 개수 (isnull) ---  
categoryid      0  
parentid        25  
dtype: int64
```

어떤 카테고리들이 있는지 알 수 있는 **데이터/카테고리 id 별로 어떤 부모와 연결되어 있는지 확인 가능한 데이터셋**

-데이터 분석 결과-

하지만 개수가 적기에 큰 문제는 없을것이라 예상되어 삭제하지 않고 진행

데이터 구성 소개

사용 데이터셋

Events.csv

(사용자 행동 로그)

```
--- [events.csv] 결측치 개수 (isnull) ---
timestamp                0
visitorid                0
event                   0
itemid                  0
transactionid    2733644
```

사용자 id, 각 상품별 고유 id등을 담은 핵심 분석 데이터

-데이터 분석 결과-

transactionid 결측치가 많은 이유

→ 모든 상품에 대해서 구매가 이루어지지 않는기 때문에 자연스러운 수치임.

item_properties.csv

(20275902, 4)


value 해석 불가로 해당 칼럼은 제거 후 진행

X, Y 분석

이벤트 분포

view 96.7%, AddToCart 2.5%, Transaction 0.8%

→ 구매보다 조회에 극도로 쏠림




상품 분석

총 상품 235.061개

50%는 3회 이하의 행동 → 데이터 희소성

상위 10%의 상품이 트랙픽 62.4% 차지



X, Y 분석

사용자 분석

총 사용자: 1,407,580 명

71%는 한 번만 행동 → **Cold Start 문제가 심각함**

1회 사용자 제거 후에도 롱테일 유지

활성 사용자: 406,020명(전체의 29%)

전환 퍼널

총 상품 235.061개

Noise 사용자 71.2%

장바구니 사용자의 68.9%가 구매로 이어지지 않음



->리타게팅 타이밍: **‘장바구니 담은 후 16분 이후’부터 가장 효과적**

시간대/요일별 행동

시간대: **16~20시 구매 집중, 0~2시 심야 구매복 존재**

요일별: **월~목 구매 활발, 주말에는 급감**

→ **주중/저녁 시간대 집중 마케팅 필요**



EDA 결과 - EVENT.CSV(1)

데이터 수집 기간 확인

[TIMESTAMP COLUMN]

기존 INT형 → **DATETIME형 변환**

시간의 흐름에 따른 데이터 분석 가능

총 데이터 수집 기간은 약 **137일**

```
--- 데이터 수집 기간 (events.csv 기준) ---  
데이터 시작일: 2015-05-03 03:00:04.384000  
데이터 종료일: 2015-09-18 02:59:47.788000  
총 수집 기간: 137 days 23:59:43.404000
```


EDA 결과 - EVENT.CSV(2)

이벤트 데이터 비율

전체 데이터: 2756101

view(제품 조회): 2664312건


addtocart(카트 담기): 69332건

transaction(구매): 22457건

View의 비율이 약 96%로 압도적으로 높음

다음으로 Add to Cart가 2.5%

Transaction이 0.8% 비중을 차지함



EDA 결과 - EVENT.CSV(3)


사용자별 행동 수 분석

mean: 1.96
25%: 1.00
50%: 1.00
75%: 2.00

75% 퍼센트의 사용자가
2번의 행동밖에 하지 않음

롱테일 분포이고
cold start 문제가 있음을 확인

전처리를 통해
무의미한 데이터는 영향력을 줄이거나 제거 필요



EDA 결과 - EVENT.CSV(4)


사용자 세그먼트

총 사용자: 1407580명

앞선 사용자마다의 행동을 분석해
사용자를 3가지 그룹으로 분류함

1회 행동 사용자는 noise로 제거하고 진행

- 1. Browser(단순 방문객): 91.1%
- 2. Shopper(장바구니 이탈자): 6.1%
- 3. Buyer(구매 고객): 2.9%



EDA 결과 - EVENT.CSV(5)

핵심 이탈 구간

2개의 핵심 이탈 구간 파악


- 1. 1회 행동 이탈자(약 71%)
- 2. 장바구니 이탈(67.9%)
 - 장바구니 O, 구매 X

1회 행동자 전처리 진행

→ 모델 정확도 향상

장바구니 사용자 - target 공략

→ CVR(구매 전환률) 향상



EDA 결과 - EVENT.CSV(6)

상품별 행동 수

총 상품 개수: 235061명

mean: 11.73


std 37.03

50%: 3.00

75%: 9.00

사용자 행동수와 비슷하게
롱테일 분포를 보임

상품에서도 **cold start**
문제가 있음을 확인




EDA 결과 - EVENT.CSV(7)

상품별 행동 수 - 파레토 분석

20% 상품이 전체 event 중 77.5%

극심한 쓸림 현상과 인기 편향성을 명확하게 보여줌

인기 편향성에 의한 추천 모델이
비슷한 상품들만 계속 추천할 위험 확인



EDA 결과 - EVENT.CSV(8)

상품 구매 소요 시간

구매자 데이터 기준 사용자 별
장바구니 → 구매까지 시간 확인


50%: 5.85
75%: 16.04

50% 사용자 - 5분 이내 구매
75% 사용자 - 16분 이내 구매

0~16: 별도의 광고 없이 구매하는 시간
16분 이후: 이탈 위험군

리타겟팅 전략 도출

16분 이전: 광고 X, 비용 낭비 최소화
16분 이후: 알림 및 쿠폰 제공




EDA 결과 - PROPERTIES.CSV

재고 유무 여부

재고 있는 상품의 비율: 12.83%

모델에 재고 상태 반영




EDA 요약

- 데이터 수집 기간 약 137일
- 사용자와 상품 별 행동(EVENT) 수 파악을 통한 COLD START 존재 확인
 - 나와 비슷한 사용자가 구매한 상품을 추천해주는 협업 필터링(CF) 모델
 - 내가 구매한 상품과 비슷한 상품을 추천해주는 콘텐츠 기반(CB) 모델
 - 두 모델을 합성하여 최대한 문제 완화 예정
- 사용자 세그먼트 정의
 - BROWSER(단순 방문객), SHOPPER(장바구니 이탈자), BUYER(구매 고객)
- 상품 구매 소요 시간 분석을 통한 리타겟팅 전략 도출
 - 16분 이전: 광고 X, 비용 낭비 최소화
 - 16분 이후: 알림 및 쿠폰 제공
- 재고의 유무 존재 확인

추천 시스템 구조


추천 시스템 파이프라인



전처리


1. 이상치 제거: Isolation Forest

- 모델의 학습에서 편향된 결과를 출력하지 않도록 이상 사용자 제거
- 여러 개의 DT로 구성되며, Root Node에 가까울수록 이상치로 판정




2. 사용자 군집화: K-means Clustering

- 비슷한 사용자끼리 묶어 데이터 사이의 관계 파악을 용이하게 함
- 근처의 사용자끼리 묶어 하나의 군집으로 분류



3. 추천 물품 후보 생성: Item2Vec (Word2Vec)

- 각 상품의 관계를 벡터값으로 변환
- 30분 이내의 활동으로 구성된 한 세션 내의 상품 관계 파악
- 문장 내의 단어에 대한 관계를 파악하는 Word2Vec과 달리 Item2Vec은 한 세션 내의 상품에 대한 관계 파악



협업 필터링

4. 협업 필터링: ALS (Alternating Least Squares)

- 나와 비슷한 사용자가 구매한 상품 추천
- OLS를 통해 상품의 특성 행렬과 사용자의 취향 행렬을 교대로 업데이트하며 손실 최소화


$$\begin{array}{c} \text{User} \end{array} \begin{array}{c} \text{Item} \\ \text{W} \quad \text{X} \quad \text{Y} \quad \text{Z} \end{array} \begin{array}{c} \text{A} \\ \text{B} \\ \text{C} \\ \text{D} \end{array} \begin{array}{|c|c|c|c|} \hline & & 4.5 & 2.0 \\ \hline 4.0 & & & 3.5 \\ \hline & 5.0 & & 2.0 \\ \hline & 3.5 & 4.0 & 1.0 \\ \hline \end{array} = \begin{array}{c} \text{A} \\ \text{B} \\ \text{C} \\ \text{D} \end{array} \begin{array}{|c|c|} \hline 1.2 & 0.8 \\ \hline 1.4 & 0.9 \\ \hline 1.5 & 1.0 \\ \hline 1.2 & 0.8 \\ \hline \end{array} \times \begin{array}{c} \text{W} \quad \text{X} \quad \text{Y} \quad \text{Z} \end{array} \begin{array}{|c|c|c|c|} \hline 1.5 & 1.2 & 1.0 & 0.8 \\ \hline 1.7 & 0.6 & 1.1 & 0.4 \\ \hline \end{array}$$

Rating Matrix User Matrix Item Matrix

콘텐츠 기반 필터링

5. 콘텐츠 기반 필터링: GNN (Graph Neural Network)


- 내가 관심있는 상품과 유사한 상품 추천
- 그래프 구조의 데이터를 통해 각 노드를 표현하는 임베딩을 만든 후, 이웃 노드들의 정보를 이용해 개별 노드 업데이트



최종 조정(Re-ranking)

6. 점수 합산: 가중 선형조합 + GridSearch


- Item2Vec, ALS, GNN의 결과들을 정규화한 후, 가중치를 곱해 더함
- 이 때 해당 가중치들은 GridSearch로 조정



최종 조정(Re-ranking)

7. 최종 조정 및 사용자에게 추천

- 산출된 추천 점수에 MMR(Maximal Marginal Relevance)을 적용하여 비슷한 제품만 추천하는 것을 방지함
- 이후 재고가 있는 상품에 추가적인 가중치를 곱해 최종 추천 점수 산출



THANK YOU