

팀플 EDA

2025/11/03

작성자: 박승원, 송혜은, 강윤모

사용한 Data set

1. category_tree.csv

- 어떤 카테고리들이 있는지 알 수 있다
- 카테고리 id 별로 어떤 부모 id(상위 카테고리)와 연결되어 있는지 확인할 수 있다
- column
 - categoryid: 카테고리별 id - 해당 상품이 어떤 상품인지는 모름
 - parentid: 각 카테고리별로 해당되는 부모 id

2. events.csv

- 사용자 행동 로그(조회, 장바구니, 구매)
- column
 - timestamp: event별 발생 시간
 - visitorid: 사용자 id
 - event: view(상품 조회), addtocart(장바구니 담기), transaction(구매)
 - itemid: 각 상품별 고유 id
 - transactionid: 구매가 일어나면 주어지는 id

3. item_properties_part1.csv + item_properties_part2.csv

- item 별로 고유 id와 property(categoryid)
- column
 - timestamp: 아마 아이템 등록 시간?

- itemid: item 고유 id
- property: categoryid
- value: 암호화된 브랜드와 상품 관련 정보 값
 - 해당 칼럼 정보를 해석하기 어렵기 때문에 제거하고 진행

EDA 진행

0. 라이브러리 импорт 및 파일 로드

- Properties1과 2를 합쳐서 하나의 properties.csv 파일로 진행함
- 파일 크기(행 갯수, 열 갯수)

```
events.csv: (2756101, 5)
category_tree.csv: (1669, 2)
properties.csv (통합본): (20275902, 4)
```

1. 칼럼 별 기본 정보 및 결측치 확인

1-1. events.csv

- 칼럼 크기 - (2756101, 5)
- info(칼럼 정보)

```
Data columns (total 5 columns):
#      Column      Dtype
---  -
0      timestamp   int64
1      visitorid   int64
2      event        object
3      itemid       int64
4      transactionid float64
dtypes: float64(1), int64(3), object(1)
memory usage: 105.1+ MB
```

- isnull(결측치 개수)

```
--- [events.csv] 결측치 개수 (isnull) ---
timestamp          0
visitorid          0
event              0
itemid             0
transactionid      2733644
```

- transactionid의 결측치가 많은 이유
 - 모든 상품에 대해서 구매가 이루어지지 않는기 때문에 자연스러운 수치임.

1-2. category_tree

- 칼럼 크기- (1669, 2)
- info(칼럼 정보)

```
Data columns (total 2 columns):
#      Column      Non-Null Count  Dtype
---  -
0     categoryid  1669 non-null    int64
1     parentid     1644 non-null    float64
dtypes: float64(1), int64(1)
memory usage: 26.2 KB
```

- isnull(결측치 개수)

```
--- [category_tree.csv] 결측치 개수 (isnull) ---
categoryid      0
parentid        25
dtype: int64
```

- 25개 categoryid는 부모 id가 없음.
- 그러나 개수가 적기에 큰 문제는 없을 것으로 예상하고 삭제하지 않고 진행

1-3. item_properties.csv

- 칼럼 크기- (20275902, 4)
- info(칼럼 정보)

Data columns (total 4 columns):

#	Column	Dtype
0	timestamp	int64
1	itemid	int64
2	property	object
3	value	object

dtypes: int64(2), object(2)
memory usage: 618.8+ MB

- isnull(결측치 개수)

```
--- [item_properties.csv (통합본)] 결측치 개수 (isnull) ---  
timestamp    0  
itemid       0  
property     0  
value        0  
dtype: int64
```

2. Timestamp 변환 및 데이터 기간 확인

info

#	Column	Dtype
0	timestamp	datetime64[ns]
1	visitorid	int64
2	event	object
3	itemid	int64
4	transactionid	float64

- int → datetime으로 변환 진행

데이터 수집 기간 - 약 137일치 데이터

```
--- 데이터 수집 기간 (events.csv 기준) ---  
데이터 시작일: 2015-05-03 03:00:04.384000  
데이터 종료일: 2015-09-18 02:59:47.788000  
총 수집 기간: 137 days 23:59:43.404000
```

3. event.csv(핵심 행동 데이터) 분석


3-1. 이벤트별 개수

```
--- [2-1] 이벤트(Event)별 개수 ---  
event  
view          2664312  
addtocart      69332  
transaction    22457
```

3-2. 이벤트별 비율

view	96.6696%
addtocart	2.5156%
transaction	0.8148%

이벤트(Event) 유형별 분포



- 이벤트가 View에 96.7% 로 쏠려 있음을 확인함
 - 나중에 상품을 추천해주는 모델에 사용할 때 참고해서 가중치를 정해주면 좋을 듯 하다.

- 1회 사용자(1,001,560명) 제거 후 이벤트 유형별 분포

--- '활성 사용자' 이벤트별 개수 ---

event


view 1665359

addtocart 66795

transaction 22387

- 사용자 필터링 후 이벤트 분포 도넛 차트

'활성 사용자'(2회+)의 이벤트 유형별 분포



- 기존 구매비율 0.8% → 1.3%, 카트담기 비율 2.5% → 3.8%로 상승
 - 진짜 고객(활성 사용자)'의 행동 풀에서는 '구매(Transaction)'와 '장바구니(Cart)' 이벤트의 중요도가 (전체 대비) 훨씬 높아짐

3-3 총 고유 사용자(visitor) 수: 1407580명

- event.csv에서 행동한 id의 수를 중복 없이 셸 때 수

3-4 사용자별 행동 수 통계

- 결과


```
--- [2-2] 사용자별 행동(event) 수 통계 ---  
count 1407580.00
```

mean	1.96
std	12.58
min	1.00
25%	1.00
50%	1.00
75%	2.00
max	7757.00

- 50% 이하의 사람들은 사이트에 들어와서 1번의 행동만 함
- 75% 이하의 사람들은 사이트에 들어와서 2번의 행동만 함
- cold start 문제가 있을 것으로 예상됨

3-5 사용자별 행동 수 히스토그램 + 해석

- 히스토그램 - 20회 이상의 행동은 보편적이지 않다 판단하고 제거해 eda 진행 함



- X축: 사용자별 총 횟수, Y축: 사용자 수(명), Y값 * 1000000 해줘서 계산하면 됨
- 대부분의 사용자가 3회 이상 행동하지 않고 나간다는 것을 알 수 있다
- 롱테일 분포의 표가 나옴
- 행동 수가 한 번인 사용자 1001560(백만)명임.
 - 한 번만 행동한 것은 굉장한 노이즈로 볼 수 있음

- 사용자별 총 행동 횟수를 기준으로 봤을 때 사용자 Cold Start' 문제가 매우 심각
- 추천 모델을 학습시킬 때 이 'Noise' 그룹을 어떻게 처리할지(제외할지) 생각해 봐야 된다
 - 가중치 or 1 데이터 제거

• 20회 이상 행동한 사용자 수


- 20회 이상 행동한 사용자
 총: 6610 명
 (전체 사용자 1407580 명 중 0.47%)

• 1회 사용자 제거 후 사용자 수 + 히스토그램

- 1회 사용자를 제거해도 롱테일 분포가 심각하다는 것을 알 수 있음
 - 사용자들은 사이트에 들어와 행동을 많이 하지 않는다는 것을 알 수 있음

- 1회 사용자 제거 후 사용자 수
 총: 406020 명

* 1회 사용자 1,001,560 명 제외



- **cold start 정의**

- **정의:** 사용자의 선호도나 행동에 대한 정보가 충분하지 않아 적절한 제품이나 콘텐츠를 추천하기 어려운 문제
-

3-6. event 내 상품 수: 235061개


- 상품 중 event(view, addtocart, transaction)를 한 번이라도 경험한 것
-

3-7. 상품별 행동 수 통계

-[2-3] 상품별 행동(event) 수 통계

count	235061.00
mean	11.73
std	37.03
min	1.00
25%	1.00
50%	3.00
75%	9.00
max	3412.00

3-8. 상품별 행동 수 히스토그램




- 50%이하의 상품은 3회 이하의 행동 횟수를 보여준다
- cold start의 문제가 상품별 행동 수 히스토그램에서도 확인 가능함
- 협업 필터링이 학습할 데이터가 부족한 '비인기 상품'이 대다수임을 의미함

3-9. 상품별 행동 수 파레토 분석: 소수의 상품이 전체 이벤트에서 비중을 크게 차지한다

'쏟림 현상'을 시각화하기 위해 **2개의 도넛 차트**를 나란히 비교 진행

- **왼쪽 차트:** '상품 수' 기준 (극소수의 핵심 상품 vs 나머지 상품)
- **오른쪽 차트:** '이벤트 수' 기준 (핵심 상품의 트래픽 vs 나머지 트래픽)


파레토 분석: 단 0.8%의 상품이 전체 이벤트의 20%를 독점



- 0.8%(1821개)의 상품이 20%의 트래픽을 가져간다
- 극심한 '쏠림 현상'과 인기 편향성을 명확하게 보여준다
- 인기 편향성(Popularity Bias)에 의해 추천 모델이 이 상품들만 계속 추천할 위험(Risk)이 있다


3-10. 상위 20개 상품의 행동 수

Y: 총 행동 횟수(건), X 상품 ID



3-11. 시간대/요일별 분석 - 언제 사람들이 많이 행동할까?


- 시간대별 이벤트 분석
 - Y: 총 이벤트 수(왼쪽), 구매 수(오른쪽)
 - X: 시간(시)



🔥 핵심 인사이트:

- "저녁 8시 이후는 아이쇼핑, 저녁 8시 이전(16-20시)이 진짜 구매 시간이다."
- 또한, 0시~2시에 '구매'가 반짝 급증하는 '심야 구매족' 세그먼트(분류)가 명확히 존재
- 요일별 이벤트 분석

요일별 이벤트 분석



- 설명
 - '전체' 활동 (왼쪽 차트): 트래픽은 월요일~목요일에 가장 높고, 금요일부터 감소하여 주말(토, 일)에 가장 낮다.
 - '구매' 활동 (오른쪽 차트): 이 패턴은 더욱 극단적입니다. 수요일(혹은 목요일, 깨진 라벨 중 3/4번째)에 정점을 찍고, 주말(토, 일)에는 구매가 거의 일어나지 않는다.

🔥 핵심 인사이트:

- 이 쇼핑몰은 '주말 쇼핑' 사이트가 아니다.
- 고객들은 주중(월-목)에 집중적으로 구매하며, 주말에는 활동이 급격히 줄어든다.


💡 전략적 결론 및 다음 단계

이 분석은 우리에게 "언제(When)" 마케팅을 해야 하는 지에 대한 명확한 답을 줍니다.

- 마케팅 요일: 주말이 아닌 주중(월-목)에 집중해야 합니다.
- 마케팅 시간:
 - (A-Target) 구매가 폭발하는 16시~20시 사이.
 - (B-Target) '심야 구매족'을 위한 0시~2시 사이.

3-12 사용자별 세그먼트

- **Buyer (구매 고객):** 구매 1회 이상 사용자
- **Shopper (장바구니 이탈자):** 장바구니에는 담고 구매는 안한 사용자
- **Browser (단순 활성 방문객):** 2회 이상 조회했지만 구매하지 않은 사용자




- 사용자별로 세그먼트를 진행

4. 구매 퍼널 및 전환율 분석

4-1. 핵심 이탈 구간 시각화 (도넛 차트 2개)

- 이탈 구간 1
 - 1회 행동 이탈
- 이탈 구간 2
 - 장바구니 사용자

3-2 분석: 두 개의 핵심 이탈 구간



1. **[왼쪽] Noise 문제:** 전체 방문자의 71.2%가 추천 모델이 작동하기도 전에 떠나는 '노이즈'이다.

2. **[오른쪽] Target 문제:** 하지만 일단 장바구니에 담은 '진짜 고객' 3.7만 명 중 68.9%가 구매를 포기한다.


결론: 우리의 전략은 [1번] Noise를 제거하여 모델 정확도를 높이고, [2번] Target을 집중 공략하여 CVR을 높여보자!

4-2. 장바구니 → 구매 소요 시간 통계 + 히스토그램

- 구매자(11,719명)으로 진행

--- '첫 장바구니 → 첫 구매' 소요 시간(분) 통계 ---


```
count    10447.00
mean      832.71
std       6381.11
min        0.37
25%        3.00
50%        5.85
75%       16.04
max     154555.82
```



- 구매자 중 50%는 약 5분만에 구매를 진행함.
- 구매자 중 75% 이내의 사람이 16분 이내에 구매함.
- 인사이트
 - **0~16분:** 고객의 75%가 스스로 구매하는 시간이다. 이때 마케팅을 하면 오히려 방해가 됨. (비용 낭비)
 - **16분 이후:** 16분이 지났는데도 구매하지 않았다면, 그 고객은 '장바구니 이탈 그룹 (68.9%)'이 될 확률이 매우 높은 '**이탈 위험군**'입니다.
 - 따라서 리타게팅(알림, 쿠폰)은 **16분이 지난 시점부터** 시작하는 것이 가장 효율적이다.

4-3. 전체 상품 중 재고 있는(구매 가능한) 상품 비율 확인

전체 상품 중 구매 가능(Available=1) 비율



- 진행하면서 상품의 99%가 categoryid를 가지고 있어 contents 기반 추천할 때 큰 어려움 없이 진행할 수 있을 것이라 예상함
- 카테고리트리를 통해 최상위 카테고리 매핑을 진행 가능.