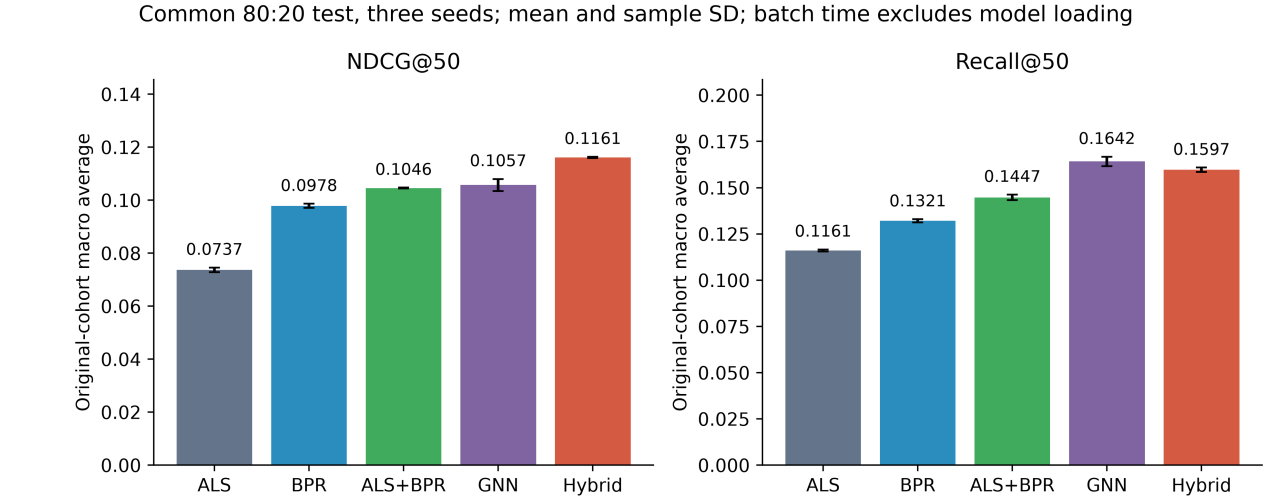
Hybrid 추천 모델 개정 실험 보고

권유희 교수님 검토용 · 2026년 10월 17일 · 공통 시간순 분할과 실제 재실험 결과

Hybrid의 두 지표 동시 1위 목표는 달성하지 못했습니다. 공통 시간순 80:20 분할에서 seed 42·43·44의 평균을 비교했습니다. Hybrid의 NDCG@50은 0.116096, Recall@50은 0.159659입니다.

각 지표의 가장 강한 비교 모델 대비 상대 차이는 NDCG +9.81%, Recall -2.75%입니다. 이 문서의 결과는 기존 논문의 점수를 재사용하지 않고 이번 실행에서 산출한 값입니다.

모델	NDCG@50 평균 ± SD	Recall@50 평균 ± SD
ALS	0.073666 ± 0.000878	0.116106 ± 0.000516
BPR	0.097831 ± 0.000797	0.132095 ± 0.000877
ALS+BPR	0.104564 ± 0.000162	0.144725 ± 0.001478
GNN	0.105724 ± 0.002282	0.164182 ± 0.002525
Hybrid	0.116096 ± 0.000275	0.159659 ± 0.001197



	ALS	BPR	ALS+BPR	GNN	Hybrid
CPU batch (s)	1.889	1.950	2.238	1.807	8.180

정답은 시험 구간의 장바구니·구매 상품 집합입니다. 모든 모델의 성적표 분모는 동일한 854명이며, Hybrid에서 추천 목록이 없는 425명도 0점으로 포함했습니다. ±는 세 seed의 표본 표준편차이며 신뢰구간과 다릅니다.

각 seed에서 평균적으로 MF만 정답을 포함한 사용자는 16.3명, GNN만 정답을 포함한 사용자는 30.0명이었습니다. 두 모델이 맞히는 대상이 다르다는 점을 사용자별 추천 목록에서 확인했습니다. 이 차이가 실제 Hybrid 이득으로 이어지는지는 뒤의 통제 비교와 신뢰구간을 함께 봐야 합니다.

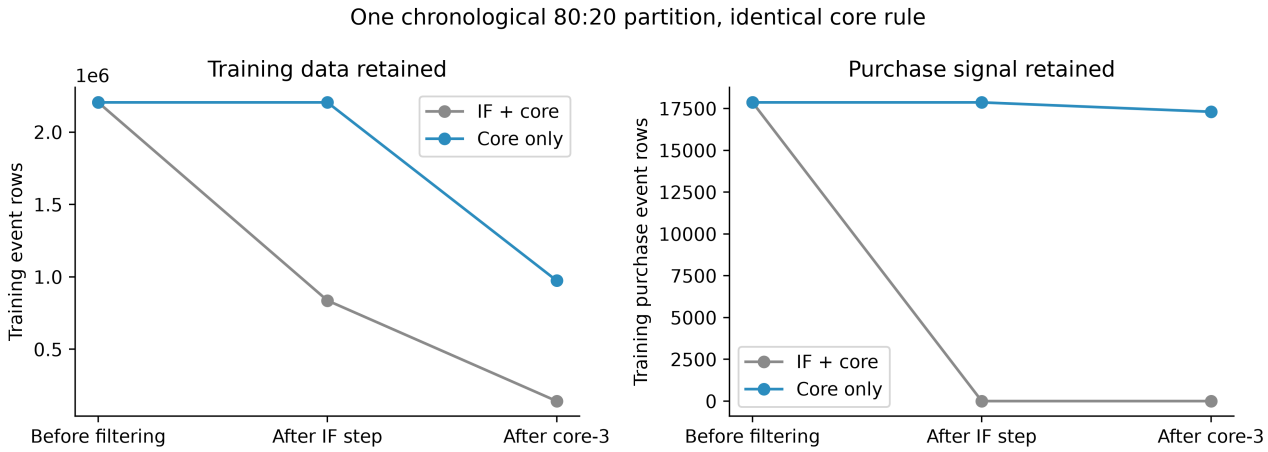
분할과 구매 제거 문제를 확인한 결과

학습 구간에서 validation을 분리하고 설정 선택 후 재학습하는 것은 정상입니다. 이번 분할은 상품 ID가 아닌 이벤트 기준입니다. 학습에 등장했던 상품만 점수를 낼 수 있으며, 미학습 상품은 original 정답에서 실패로 남깁니다.

구간	필터 전 이벤트	core 이후 학습 이벤트	용도
내부 학습	1,763,904	772,302	모델 학습
내부 validation	440,976	해당 없음	epoch와 설정 선택
최종 재학습	2,204,880	974,155	설정 확정 후 재학습
바깥 test	551,221	해당 없음	최종 성능 계산

원본 코드 재구성 자료에서는 학습 pair와 validation pair의 직접 중복은 0개였습니다. 그러나 validation 139,306개가 모두 분할 전에 생성한 전파 그래프에 들어 있었습니다. 이번 구현은 내부 학습 구간만으로 그래프를 만듭니다.

original 평가자는 854명이고, 사용자 벡터가 남는 사람은 429명입니다. 정답 상품까지 남는 conditional 평가자 409명과는 다릅니다. 현재 지원 범위에서 전체 카탈로그를 이상적으로 정렬한 Recall@50 상한은 0.4451입니다.



동일 8:2 구간에서 IF를 적용하면 학습 구매 17,864건이 IF 단계에서 모두 제거됐습니다. IF 없이 core만 적용하면 17,305건이 남습니다. 원본 코드 재구성에서도 학습 구매는 0건이므로 8:2 통일 뒤 새로 생긴 문제라고 단정하지 않습니다. 재구성 자료는 투고 당시 원본 실행 기록을 대신하지 않습니다.

학습 구간 IF 특징 비교	IF 이후 남은 구매
원래 9개 특징	0
행동코드 평균과 표준편차 제외	3,476
행동코드 평균과 표준편차만 사용	0

원래 설정을 재적합한 라벨은 저장 라벨과 100.0% 일치했습니다. 행동코드 특징을 제외하면 구매 일부가 복구되지만 대부분은 여전히 제거됩니다. 따라서 행동코드만의 단독 문제로 설명할 수 없습니다.

코드에서 바꾼 부분과 선택 근거

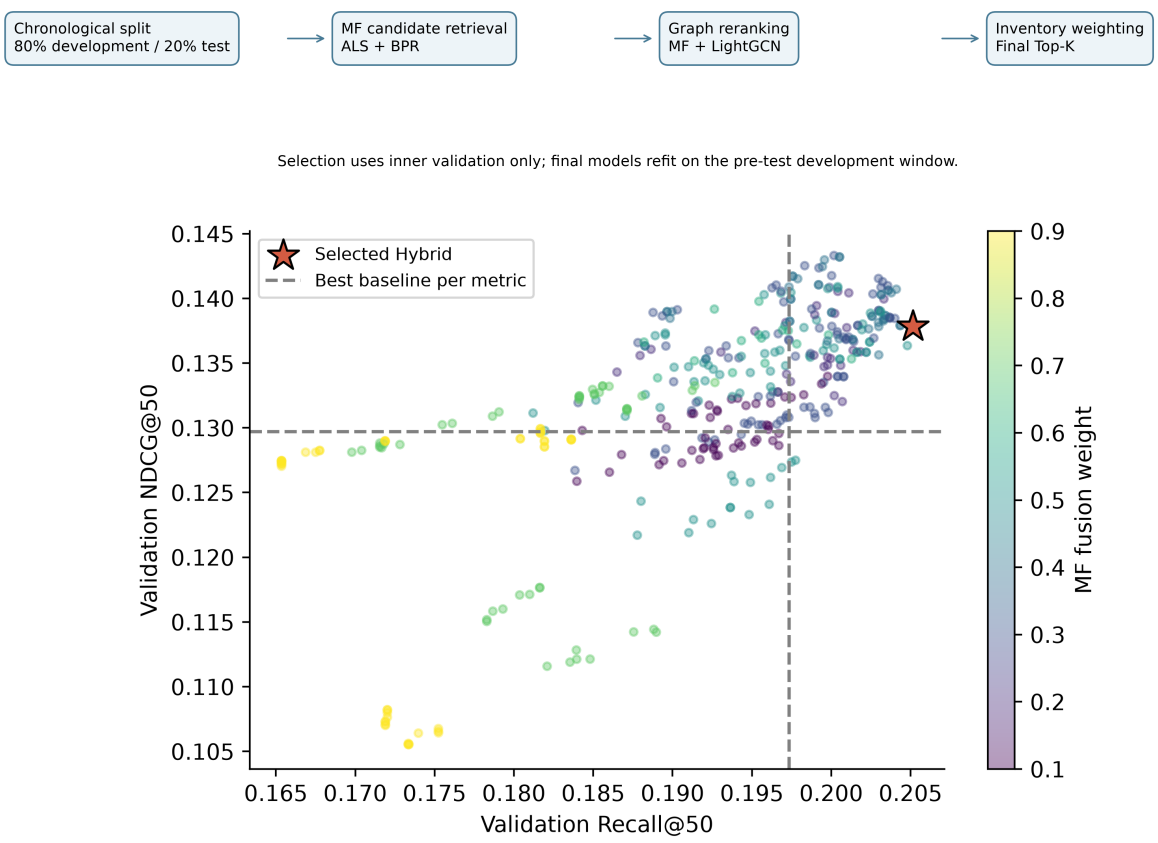
MF 신호 보존 원고 식 8은 후보 점수인 ALS+BPR과 GNN 점수를 결합합니다. 기존 코드는 최종 결합에 ALS만 사용했습니다. 이를 수정해 BPR이 후보 검색 이후에도 최종 순위에 기여하도록 했습니다.

후보 검색 MF 결합 점수로 검색하는 방식과 ALS·BPR 후보를 균형 있게 합치는 방식을 비교했습니다. GNN으로 전체 카탈로그를 검색하는 방식으로 바꾸지는 않았습니다.

공동 선택 기준 validation NDCG만 최대화하는 대신 NDCG와 Recall의 상대 개선율 중 작은 값을 최대화했습니다. 한 지표가 좋아지는 대신 다른 지표가 나빠지는 설정을 피하려는 기준입니다.

GNN 학습 64차원 2층·3층 LightGCN에서 행동 가중 InfoNCE를 사용했습니다. 음성 수는 32개, 온도는 0.2입니다. 균등·MF 기반 혼합 표본을 비교하고 학습 이력 상품을 음성에서 제외했습니다. 학습 MF도 같은 학습 구간만 사용합니다. 원고의 GNN BPR 손실 설명은 실제 목적함수에 맞춰 수정해야 합니다.

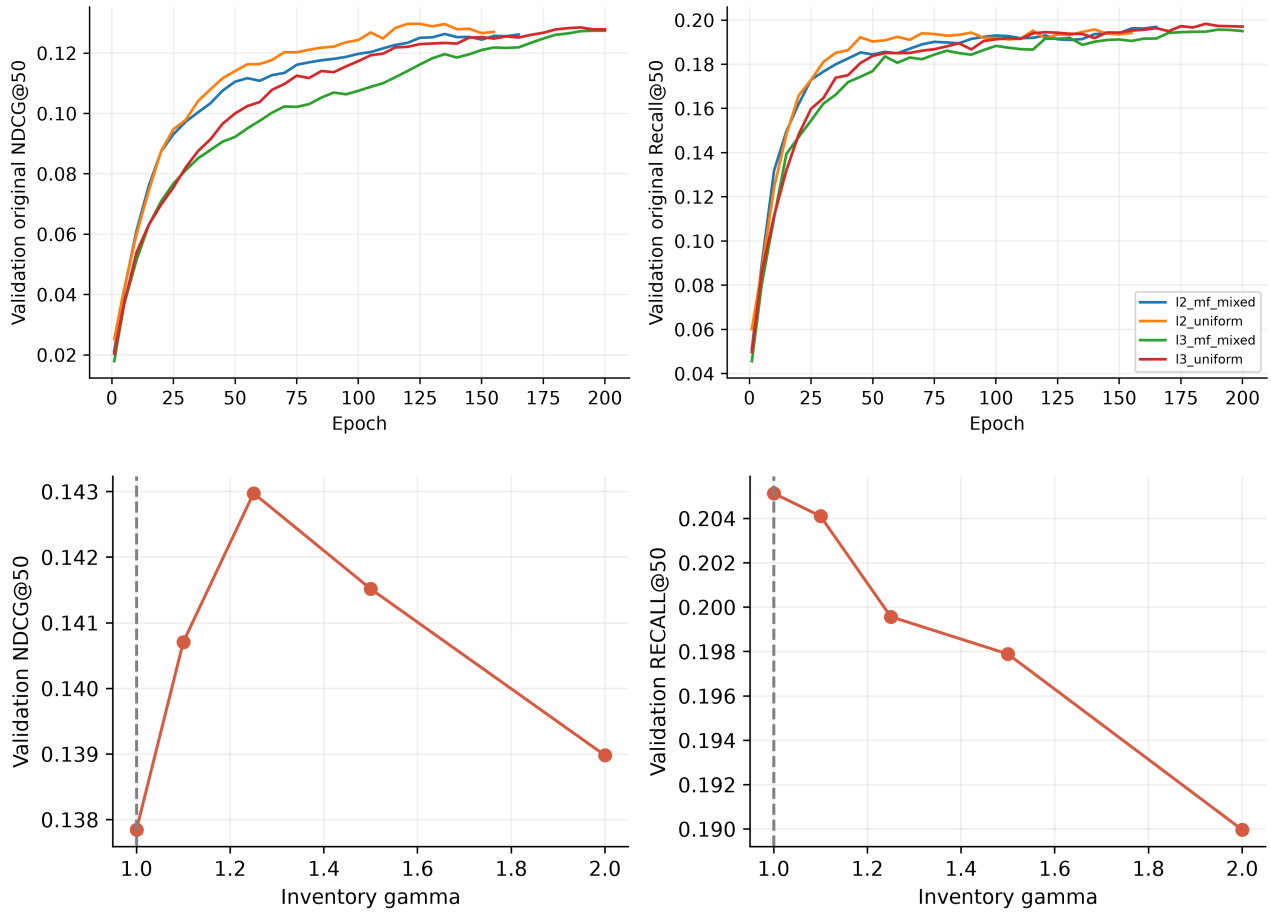
최종 융합 후보 안에서 MF와 GNN 점수를 각각 min-max 정규화한 뒤 가중합합니다. MF 점수는 ALS 단독이 아니라 ALS+BPR 결합 점수입니다.



점선은 각 지표의 가장 강한 validation 비교 모델을 나타냅니다. 별표는 공동 기준으로 선택한 Hybrid입니다. 점과 색은 실제 설정 탐색 CSV에서 생성했습니다.

학습과 하이퍼파라미터 선택 결과

항목	선택값
GNN 조건	2층 · mf_mixed · 64차원
Hybrid 학습 길이	130 epoch
후보 검색	balanced_union
후보 수	10000
ALS 비중과 MF 융합 비중	후보 alpha 0.25 · 최종 omega 0.4
최종 융합과 재고 가중	minmax · gamma 1.0

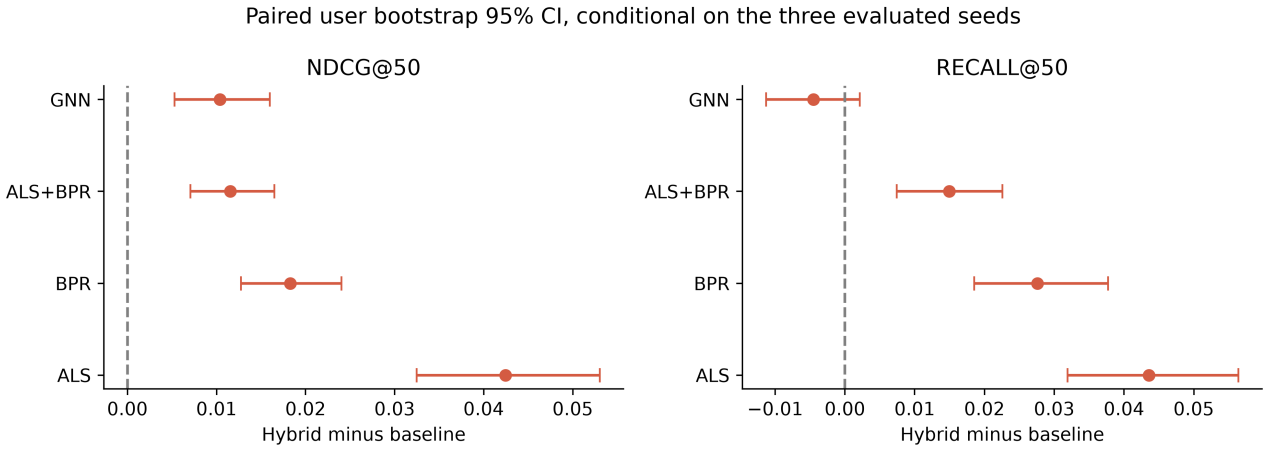


학습 곡선과 gamma 민감도는 모두 내부 validation 결과입니다. 최종 test 곡선을 보고 gamma나 epoch를 선택하지 않았습니다. gamma가 1이면 재고 가중은 중립입니다.

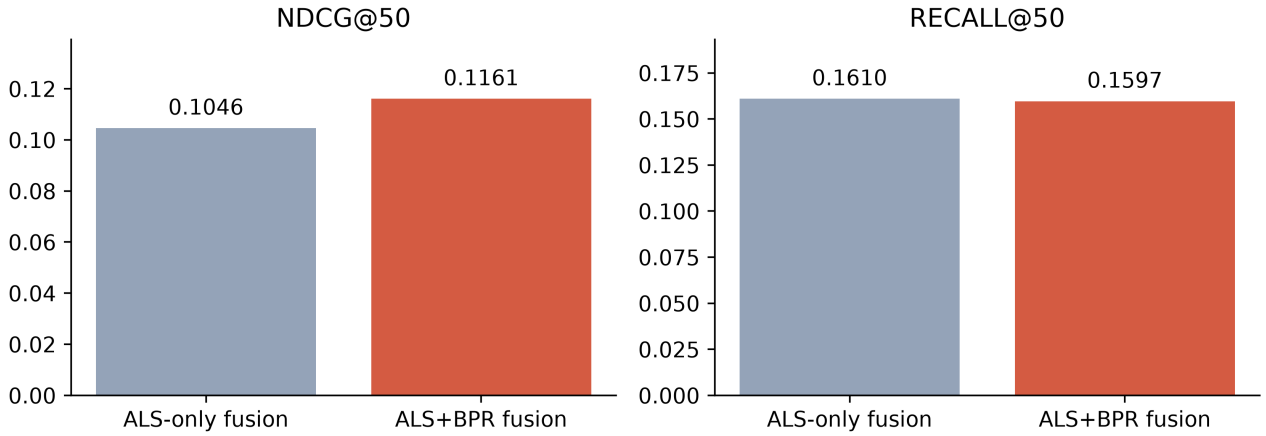
재고 가중은 학습 종료 전에 관측한 마지막 available 값을 사용하고 미상 상품에는 부스팅을 적용하지 않습니다. 시험 기간의 실시간 재고나 매출 효과를 검증한 결과는 아닙니다.

validation에서 실제 출력된 추천 항목 중 알려진 가용 상품 비율은 중립 가중에서 74.6%, 선택한 가중에서 74.6%였습니다. 이 항목 비율의 분모는 출력된 추천 수이며 성능 지표의 사용자 분모와 다릅니다.

효과의 범위와 교수님 질문에 대한 답변



사용자 단위 paired bootstrap 95% 신뢰구간을 계산했습니다. 8개 비교 중 하한이 0보다 큰 비교는 7개입니다. 이 구간은 평가한 세 seed에 조건부인 사용자 불확실성이며, 다른 시점이나 다른 데이터셋에 대한 일반화 증거는 아닙니다.



통제 조건	NDCG@50	Recall@50
Hybrid 전체	0.116096	0.159659
재고 가중 없음	0.116096	0.159659
GNN 점수 없음 같은 재고 가중	0.105765	0.138651
MF 점수 없음 같은 후보와 재고 가중	0.102381	0.160832
동일 GNN 가중치 전체 상품 평가	0.101848	0.160313

Validation이 학습에 중복됐는가 원본의 문제는 파일 pair 중복이 아니라 전파 그래프에 검증 관계가 남은 것이었습니다. 이번 검증 단계와 최종 재학습 단계는 분리되어 있습니다.

왜 구매가 제거됐는가 구매 이력이 있는 상품들이 IF 이상치로 분류되면서 해당 상품의 모든 이벤트가 제거됐습니다. 행동코드 두 특징을 제외하면 구매 3,476건이 남지만 14,388건은 여전히 제거됩니다. 행동코드와 나머지 특징들의 영향을 함께 봐야 하며, 봇을 식별한 결과로 설명하지 않습니다.

원고에서 수정할 내용 공통 8:2와 정답 집합, 식 6~9의 실제 점수 계산, 이분그래프 구조, 데이터 손실 통계, 성능과 실행 시간 표, 그림 번호와 해상도를 함께 수정해야 합니다. 속성·카테고리 그래프 및 cold-start 해결 주장은 현재 구현에 맞게 조정해야 합니다.

재현 방법과 판단의 한계

최종 설정은 selection.json으로 확정한 뒤 재학습했고, 각 seed의 완료 파일은 그 설정 해시를 참조합니다. 학습·추천·평가의 원본 CSV와 사용자별 지표를 함께 저장했습니다. synthetic 회귀검사는 프로토콜 확인용이며 실제 데이터 성능으로 사용하지 않았습니다.

이번 전체 실행 기록의 소요 시간은 1.95시간입니다. 학습 환경과 장비는 experiment_plan.json, 코드 및 데이터 식별자는 각 manifest에 기록했습니다.

과거 프로젝트의 test 결과는 이번 작업 전에 이미 검토된 상태입니다. 이번 설정 탐색은 내부 validation에서만 진행했지만, 이 자료를 연구 전체에서 한 번도 관찰하지 않은 독립 시험이라고 부르지는 않습니다. 단일 데이터셋·단일 시간 구간·세 seed의 정정 평가라는 범위를 명시합니다.

투고 원고의 NDCG 0.3710과 Recall 0.7113은 이번과 데이터 분할·후보 처리·평가 분모가 다릅니다. 해당 숫자와 이번 결과를 같은 조건의 전후 성능으로 비교하거나 상대 개선율을 계산하지 않습니다.

모델	학습 초	배치 추천 초	사용자당 환산 ms
ALS	80.8	1.889	4.40
BPR	45.7	1.950	4.55
ALS+BPR	126.5	2.238	5.22
GNN	1200.1	1.807	4.21
Hybrid	924.7	8.180	19.07

추천 시간은 모델 로딩을 제외하고 사용자 배치를 CPU에서 3회 실행한 중앙값을 seed별로 구한 뒤 평균한 값입니다. 사용자당 값은 배치 시간을 나눈 환산치이며 온라인 응답 지연시간이 아닙니다. MF 기반 음성 채굴을 사용한 GNN의 학습 시간에는 MF 의존 비용을 포함합니다.

이 측정에서 Hybrid의 배치 추천 시간은 GNN 단독의 4.53배였습니다. GNN 점수를 계산하는 후보 수가 줄어도 MF 검색 비용이 추가되므로 전체 속도 향상을 보장하지는 않습니다. 원고의 계산 효율 우위 주장은 이 측정 범위에 맞춰 수정해야 합니다.

재현 명령과 파일별 위치는 같은 폴더의 README_KO.md와 상위 폴더의 README_HYBRID_KO.md에 정리했습니다. 결과 CSV, 실행 로그, 선택 근거와 소스는 함께 보존했습니다.

재실행 예시: 지정 Python 환경에서 improve_hybrid.py에 --source-dir로 공통 no_if_events 준비 데이터 경로를 전달하고 --output-dir에 새 빈 결과 폴더를 지정합니다. 기존 결과 디렉터리에 다른 코드나 설정으로 이어 쓰지 않습니다.

제안된 알고리즘 수정과 결과는 연구팀의 검토를 위한 자료입니다. 교수님께 직접 전송하거나 논문을 재투고하는 작업은 수행하지 않았습니다.